

Arbeitsblatt: Klassifikation von Netzwerkverkehr mit KI-Methoden

Wintersemester 2025/26

Zielsetzung

In dieser Aufgabe sollen Sie Methoden des maschinellen Lernens anwenden, um Netzwerkverkehr in bereitgestellten Mitschnitten zu klassifizieren. Die Aufgabe ist in zwei Hauptteile gegliedert: die Erkennung von Verkehrsarten mittels *Unsupervised Learning* und die anschließende Nutzung der Ergebnisse für das Training eines *Deep Learning* Modells.

Ausgangsmaterial

- Individuelle Netzwerkmitschnitte in Form von Flows
Navigieren Sie dazu im JupyterHub (<https://hub2.tikube.informatik.uni-halle.de/>) zu folgendem Pfad:
`shared-material / KI und IT-Sec / XX_Semesterprojekt / Dateien`
(Wählen Sie dort die Datei aus, die auf Ihren Nachnamen endet.)
- Ausgewählte PCAP-Dateien

Anforderungen

- Alle Lösungen und Ergebnisse sollen in einem **Jupyter Python Notebook** dokumentiert werden.
- Verwenden Sie Python-Bibliotheken für Datenanalyse und maschinelles Lernen, z. B. `pandas`, `numpy`, `scikit-learn`, `tensorflow` oder `keras`.

Aufgabenstellung

Teil 1: Unsupervised Learning

1. Datenvorbereitung

- Laden Sie die bereitgestellten Netzwerkmitschnitte in Ihr Python-Umfeld.
- Wählen Sie geeignete Features aus den Daten, die für die Klassifikation des Netzwerkverkehrs relevant sein könnten.

2. Clustering

- Wenden Sie Methoden des Unsupervised Learning (wie z.B. K-Means oder DBSCAN) an, um die Daten in verschiedene Cluster zu unterteilen.
- Visualisieren Sie die Cluster und interpretieren Sie die Ergebnisse.

3. Labeling

- Analysieren Sie die Cluster, um zu bestimmen, welche Arten von Netzwerkverkehr (z. B. HTTP, FTP, DNS) sie repräsentieren.
- Weisen Sie den Clustern entsprechende Labels zu.

4. Validierung

- Prüfen Sie die Stichhaltigkeit Ihrer Verfahren, z. B. durch Vergleich mit bekannten Labels oder durch manuelle Inspektion von Stichproben.

Teil 2: Deep Learning

1. Erstellung eines gelabelten Datensatzes

- Nutzen Sie die gelabelten Daten aus dem Unsupervised Learning (Teil 1), um einen größeren gelabelten Datensatz zu generieren.

2. Modellauswahl

- Wählen Sie ein passendes Modell für ein neuronales Netz, um den Netzwerkverkehr zu klassifizieren.
- Begründen Sie Ihre Wahl (Architektur, Layer, Aktivierungsfunktionen).

3. Training des Modells

- Trainieren Sie das ausgewählte Modell mit dem generierten Datensatz.
- Evaluieren Sie die Leistung des Modells anhand geeigneter Metriken (z. B. Accuracy, Precision, Recall, F1-Score).

4. Ergebnisse und Diskussion

- Diskutieren Sie die Ergebnisse des Deep Learning Modells.
- Welche Verbesserungen könnten vorgenommen werden?
- Wie gut ist das Modell für den Einsatz in realen Netzwerken geeignet?

Abgabe & Hinweise

Abgabeformate:

- **Abgabedeadline:** 18.01.26 um 23:59 Uhr
- **Abgabeort:** Abgabeordner der Stud.IP-Veranstaltung
- Reichen Sie das Jupyter Notebook mit allen Implementierungen, Visualisierungen und Diskussionen ein.
- Stellen Sie sicher, dass der Code gut dokumentiert und die Ergebnisse nachvollziehbar sind.

Hinweise zur Bearbeitung:

- Nutzen Sie Literatur und Online-Ressourcen, um sich in die Themen einzuarbeiten.
- Arbeiten Sie jeweils auf den Ihnen zugewiesenen Datensets.
- Der Austausch in Gruppen von 2–3 Personen ist erlaubt und erwünscht, die Abgabe muss jedoch eigenständig erfolgen.
- Bei Rückfragen stehe ich Ihnen gern per Mail (toni.matthes@informatik.uni-halle.de) zur Verfügung

Viel Erfolg!